

Análisis Exploratorio de Datos: Fórmula 1

Laboratorio de Datos 1

Luca Franco Mengarelli

2026-06-21

1. IMPORTACIÓN Y LIMPIEZA

```
# Leer las bases de datos y limpiar nombres
carreras <- read_csv("data/carreras.csv") %>% clean_names()
conductores <- read_csv("data/conductores.csv") %>% clean_names()
constructores <- read_csv("data/constructores.csv") %>% clean_names()
resultados <- read_csv("data/resultados.csv") %>% clean_names()

# Unimos las bases (JOIN)
# Primero unimos los resultados con los datos de la carrera (manteniendo todos los resultados)
df_unido <- left_join(resultados, carreras, by = "id_carrera")

# Luego sumamos los conductores y constructores
df_unido <- left_join(df_unido, conductores, by = "id_conductor")
df_unido <- left_join(df_unido, constructores, by = "id_constructor")

# Limpieza final (eliminamos el drop_na global que borraba los autos que no terminaron)
df_limpio <- df_unido
```

2. TRANSFORMACIÓN DE DATOS (VERBOS DPLYR)

```
df_final <- df_limpio %>%
  # Crear nueva columna para tener el tiempo en minutos en vez de milisegundos
  mutate(minutos_carrera = milisegundos / 60000) %>%
  # Filtrar carreras extremadamente cortas o atípicas, pero manteniendo los que no terminaron (NA)
  filter(minutos_carrera > 30 | is.na(minutos_carrera)) %>%
  # Seleccionar columnas relevantes para el análisis
  select(id_resultado, nombre.x, nombre, apellido, nacionalidad.x,
         lluvia, estado, pos_inicial, pos_final, minutos_carrera) %>%
  # Renombrar columnas para evitar confusiones post-join
  rename(
    nombre_carrera = nombre.x,
    nombre_escuderia = nombre,
    nacionalidad_piloto = nacionalidad.x
  ) %>%
```

```
# Ordenar de mayor a menor tiempo
arrange(desc(minutos_carrera))
```

3. ANÁLISIS UNIVARIADO

3.1. Variable Categórica (Cualitativa): Estado de finalización


```
# TABLA: Frecuencias y Porcentajes
tabla_cat <- tabyl(df_final, estado) %>%
  adorn_totals("row") %>%
  adorn_pct_formatting()
print(tabla_cat)
```

```
##      estado    n percent
##  Accidente  127   5.1%
##  Completada 1358  54.8%
##  Descalificado    8   0.3%
##      Otro   987  39.8%
##      Total 2480 100.0%
```

```
# GRÁFICO: Barras (ordenadas de mayor a menor)
ggplot(df_final, aes(x = fct_infreq(estado), fill = estado)) +
  geom_bar(color = "black") +
  labs(title = "Distribución de Frecuencias", subtitle = "Estado al finalizar la carrera", x = "Estado")
  theme_minimal() + theme(legend.position = "none")
```

Distribución de Frecuencias

Estado al finalizar la carrera




A partir de la tabla y el gráfico de barras, se puede observar que la categoría predominante en la variable estado es “Completada”, lo cual indica que la gran mayoría de los autos logran terminar la carrera.

3.2. Variable Numérica (Cuantitativa): Tiempo de Carrera en Minutos

```
# MEDIDAS RESUMEN
resumen_num <- df_final %>%
  summarise(
    Min = min(minutos_carrera, na.rm = TRUE),
    Q1 = quantile(minutos_carrera, 0.25, na.rm = TRUE),
    Mediana = median(minutos_carrera, na.rm = TRUE),
    Media = mean(minutos_carrera, na.rm = TRUE),
    Q3 = quantile(minutos_carrera, 0.75, na.rm = TRUE),
    Max = max(minutos_carrera, na.rm = TRUE),
    Desvio = sd(minutos_carrera, na.rm = TRUE),
    N = n()
  )
print(resumen_num)
```

```
## # A tibble: 1 x 8
##   Min    Q1 Mediana Media    Q3    Max Desvio    N
##   <dbl> <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl> <int>
## 1  73.7  88.3    94.0  98.9 100.0  184.   19.0  2480
```

```
# GRÁFICO: Histograma
ggplot(df_final, aes(x = minutos_carrera)) +
  geom_histogram(bins = 15, fill = "steelblue", color = "black") +
  labs(title = "Histograma", subtitle = "Distribución del Tiempo de Carrera", x = "Tiempo (Minutos)", y =
  theme_minimal()
```



El análisis de la variable minutos_carrera indica que la muestra tiene una distribución asimétrica. En promedio, el valor es cercano a los 90 minutos, lo que coincide con la duración estándar de una carrera de Fórmula 1.

4. ANÁLISIS BIVARIADO

4.1. Numérica vs Categórica: Tiempo de Carrera según Lluvia


```
# TABLA: Medidas resumen separadas por grupo
resumen_grupo <- df_final %>%
  group_by(lluvia) %>%
  summarise(
    Mediana = median(minutos_carrera, na.rm = TRUE),
    Media = mean(minutos_carrera, na.rm = TRUE),
    Desvio = sd(minutos_carrera, na.rm = TRUE),
    N = n()
```

```
)
print(resumen_grupo)
```

```
## # A tibble: 2 x 5
##   lluvia Mediana Media Desvio      N
##   <lgl>    <dbl> <dbl>  <dbl> <int>
## 1 FALSE     92.4  95.9   15.7  1880
## 2 TRUE      99.6 108.    24.1   600
```

```
# GRÁFICO: Boxplot comparativo
```

```
ggplot(df_final, aes(x = as.character(lluvia), y = minutos_carrera, fill = as.character(lluvia))) +
  geom_boxplot() +
  labs(title = "Distribución de Tiempos por Condición Climática", x = "¿Hubo Lluvia? (TRUE/FALSE)", y =
    theme_minimal() + theme(legend.position = "none")
```



Al analizar la distribución de tiempos segmentada por lluvia, el gráfico de cajas revela diferencias notorias entre los grupos. Específicamente, el grupo con lluvia (TRUE) presenta una mediana mayor y tiempos más prolongados en general, sugiriendo un ritmo más lento debido a la pista mojada.


4.2. Categórica vs Categórica: Estado según Lluvia

```
# TABLA: Tabla cruzada con porcentajes (Independiente en columna, Dependiente en fila)
tabla_cruzada <- tabyl(df_final, estado, lluvia) %>%
```

```
adorn_percentages("col") %>%
adorn_pct_formatting(digits = 1) %>%
adorn_ns() # Agrega la "n" original entre paréntesis
print(tabla_cruzada)
```

```
##          estado      FALSE      TRUE
##  Accidente  4.6%   (86)  6.8%   (41)
##  Completada 53.6% (1,008) 58.3% (350)
##  Descalificado 0.3%    (6)  0.3%    (2)
##          Otro 41.5%   (780) 34.5% (207)
```

```
# GRÁFICO: Barras apiladas al 100%
ggplot(df_final, aes(x = as.character(lluvia), fill = estado)) +
  geom_bar(position = "fill", color = "black") +
  labs(title = "Proporción de Estados por Condición Climática", x = "¿Hubo Lluvia?", y = "Proporción",
  theme_minimal()
```




La tabla cruzada y el gráfico de barras apiladas al 100% muestran la relación entre la condición climática y el estado de finalización. Se evidencia visualmente cómo cambian las proporciones de abandonos o accidentes cuando las condiciones son adversas.

4.3. Numérica vs Numérica: Posición Inicial vs Posición Final

```
# CORRELACIÓN: Coeficiente de Pearson
correlacion <- cor(df_final$pos_inicial, df_final$pos_final, use = "complete.obs")
print(correlacion)
```

```
## [1] 0.5918921
```

```
# GRÁFICO: Dispersión (Scatterplot)
ggplot(df_final, aes(x = pos_inicial, y = pos_final)) +
  geom_jitter(alpha = 0.5, color = "darkred", size = 2, width = 0.3, height = 0.3) +
  geom_smooth(method = "lm", se = FALSE, color = "black", linetype = "dashed") +
  labs(title = "Relación Lineal: Largada vs Llegada", x = "Posición de Largada (Grilla)", y = "Posición Final")
  theme_minimal()
```



El diagrama de dispersión y el coeficiente de correlación de Pearson indican la existencia de una fuerte relación lineal positiva entre la posición inicial y la final. Es decir, largar en las primeras posiciones está fuertemente asociado a terminar la carrera entre los primeros lugares.